

Planejamento Probabilístico e Aprendizizado por Reforço

EP 4 – MAC0425

Isis Ardisson Logullo – NUSP: 7577410

Análise comparativa dos resultados obtidos entre o algoritmo de Iteração de Valor (Programação Dinâmica focado no planejamento probabilístico com modelo conhecido) e o algoritmo Q-Learning (uma abordagem baseada em Aprendizado por Reforço livre de modelo). As avaliações foram conduzidas nos ambientes controlados Gridworld (incluindo as variantes BridgeGrid, DiscountGrid e CliffGrid) e no clássico domínio do Pac-Man.

1 Iteração de Valor

A Iteração de Valor opera atualizando iterativamente a função de valor de estado $V(s)$ com base na equação de otimalidade de Bellman. Onde os estados sucessores calculados em uma etapa k utilizam estritamente os valores sincronizados da etapa $k - 1$, garantindo a convergência matemática exata dada a natureza do Processo de Decisão de Markov (MDP).

1.1 Resultados Iniciais e Cenário BridgeGrid

No mapa padrão (Gridworld inicial), a execução com a política gulosa derivada após 100 iterações resultou em uma recompensa média de 0.4677 ao longo de 10 episódios experimentais, indicando que o agente aprendeu com sucesso o caminho mais seguro para mitigar o noise intrínseco de 20% das ações (onde 80% seguem a direção desejada e 20% divergem lateralmente). No cenário BridgeGrid, o desafio reside em atravessar uma ponte estreita cercada por abismos altamente penalizadores (-100). Foram comparadas duas configurações de parâmetros:

- **Configuração 1** ($\gamma = 1.0, noise = 0.2$): Obteve média de -49.5 .

Devido à presença do ruído estocástico alto em um ambiente sem desconto, o risco acumulado de cair nas bordas torna a travessia da ponte estatisticamente proibitiva sob uma ótica racional de longo prazo. A política resultante desencoraja o avanço agressivo, mas quando o agente tenta cruzar, o ruído gera quedas frequentes, derrubando severamente a média.

- **Configuração 2** ($\gamma = 0.9$, $noise = 0.0$): Obteve média de 5.9049. Sem o ruído, o ambiente torna-se puramente determinístico. Mesmo com o desconto temporal atenuando ligeiramente o ganho distante ($V = 10 \times 0.9^4 = 6.561$), o agente tem a certeza absoluta de sua trajetória, cruzando a ponte de forma ótima e sem qualquer queda.

1.2 Análise Paramétrica Avançada no DiscountGrid

O mapa DiscountGrid testa explicitamente o balanço entre o fator de desconto (γ), o ruído estocástico ($noise$) e o living reward. A Tabela 1 consolida as médias experimentais coletadas para as cinco configurações fundamentais do MDP.

Caso / MDP	Desconto (γ)	Ruído (Noise)	Recompensa de Vivência	Média Obtida (-k 10)	Comportamento Político Observado
MDP 1	0.1	0.0	0	0.0010	Desconto extremamente agressivo. O agente supervaloriza o presente imediato e ignora o prêmio distante (+10), preferindo a saída rápida mais próxima.
MDP 2	0.5	0.2	-2	-3.8333	Vivência altamente penalizadora. O agente busca o "suicídio planejado", colidindo de forma deliberada contra os terminais negativos (-10) para evitar a penalidade contínua de viver.
MDP 3	1.0	0.0	-1	5.0000	Ambiente determinístico com custo moderado de tempo. O agente planeja e executa a rota ideal de menor caminho em direção ao prêmio de +10 de forma consistente.
MDP 4	0.9	0.2	0	2.9335	Equilíbrio estável. O agente assume riscos moderados e contorna os perigos para alcançar o objetivo máximo, tolerando o ruído devido à neutralidade de vivência.
MDP 5	1.0	0.2	+10	Loop Infinito	Recompensa de vivência absurdamente positiva. Viver é infinitamente melhor do que encerrar o episódio. O agente evita os terminais a qualquer custo, travando voluntariamente em loops.

Tabela 1: Resumo dos experimentos e respostas políticas no domínio DiscountGrid.

2 Q-Learning

Ao contrário da Iteração de Valor, o Q-Learning opera em um regime model-free, estimando os valores de qualidade $Q(s, a)$ diretamente a partir das amostras de transição coletadas empiricamente via exploração $\varepsilon - gulosa$.

2.1 Impacto da Taxa de Exploração (ε) no Gridworld

Avaliando o agente no Gridworld padrão sobre 100 episódios de treino, notam-se variações gritantes baseadas estritamente na taxa de exploração ε , conforme detalhado na Tabela 2:

Configuração Experimental (Q-Learning)	Média Obtida	Análise de Convergência e Desempenho
Configuração Padrão (Parâmetros base do ambiente)	0.2030	Convergência intermediária lenta. Em apenas 100 episódios, o agente ainda está montando a representação do espaço de estados devido ao ruído de transição ativo.
Exploração Controlada Reduzida (noise=0.0, $\varepsilon=0.1$)	0.4928	Desempenho Ótimo. O ambiente determinístico remove a incerteza e o baixo ε garante que 90% das ações sigam a política que rapidamente convergiu para o alvo.
Exploração Hiperativa Excessiva (noise=0.0, $\varepsilon=0.9$)	0.0151	Degradação Prática. Embora o ambiente seja estável, o agente escolhe ações puramente aleatórias em 90% do tempo, agindo de forma errática e destruindo a média de score.

Tabela 2: Impacto das taxas hiperparamétricas de exploração no Q-Learning.

2.2 Comparativo Crítico no Cenário CliffGrid

O cenário CliffGrid explicita perfeitamente a diferença teórica profunda entre a Iteração de Valor e o Q-Learning. A Iteração de Valor, possuindo conhecimento pleno do modelo de transição probabilística e computando a convergência exata de Bellman sobre o horizonte infinito, deduz uma política que contorna o abismo de forma matematicamente segura, gerando valores $V(s)$ estáveis e bem distribuídos que refletem com precisão a penalidade de proximidade do perigo.

Por outro lado, o Q-Learning treinado por escassos 100 episódios exhibe valores $V(s)$ visivelmente discrepantes e inferiores. Sendo um algoritmo empírico baseado em amostragem temporal, 100 episódios são insuficientes para que o agente visite de forma exaustiva e repetida todas as combinações de par estado-ação (s, a) no limiar do penhasco. Com isso, muitas células sofrem de

sub-exploração e mantêm valores próximos de zero ou excessivamente distorcidos pelas quedas iniciais sofridas durante a exploração aleatória, ilustrando a alta dependência de dados característica de RL clássico em relação a planejadores exatos.

3 Domínio Pac-Man: Análise de Convergência e Aprendizado

A aplicação do Q-Learning ao Pac-Man introduz maior complexidade espacial. O agente treinou por 2000 episódios isolados e foi avaliado ao longo dos subsequentes 100 episódios operacionais. Os resultados foram confrontados contra o benchmark estático GreedyAgent (agente estritamente guloso reflexivo).

Cenário (Layout)	Q-Learning Média ($\alpha = 0.2$)	Q-Learning Média ($\alpha = 1.0$)	GreedyAgent Média	Análise Comparativa e Conclusões
smallGrid	499.8	Abaixo de 400 / Instável	251.33	O Q-Learning com taxa controlada ($\alpha=0.2$) aprendeu a mapear os fantasmas e rotas de pastilhas perfeitamente, superando massivamente o GreedyAgent, que frequentemente fica preso ou morre por falta de planejamento de longo prazo.
tinyCorners	Altamente Superior	Instabilidade crítica	-164.41	O GreedyAgent falha catastróficamente no labirinto de cantos (score negativo de -164.41), pois sua visão imediata o faz oscilar ou colidir. O Q-Learning estruturado consegue convergir para encontrar os cantos eficientemente após o treino.

Tabela 3: Comparativo de scores médios finais obtidos nos domínios do Pac-Man.

3.1 Análise do Hiperparametro α (Taxa de Aprendizado) no Pac-Man

A variação da taxa de aprendizado α revelou um comportamento crucial. O valor padrão de 0.2 permite uma convergência robusta e suave, integrando novas informações de forma incremental e ponderada ao histórico de utilidade acumulado.

Quando configurado com $\alpha = 1.0$, o algoritmo passa a ignorar completamente o conhecimento prévio aprendido, atualizando o valor $Q(s, a)$ para depender

única e exclusivamente da última transição observada ($Q \leftarrow r + \gamma \max(Q)$). Devido à estocasticidade do comportamento dos fantasmas e do layout, essa dependência radical do último resultado induz uma volatilidade catastrófica nas tabelas de valores, impedindo a estabilização da política e degradando severamente a taxa de sucesso final nos testes.

4 Conclusão

A **Iteração de Valor** destaca-se pela robustez e eficiência absoluta, porém exige acesso completo ao modelo do ambiente (T e R), o que é inviável em cenários reais complexos. O **Q-Learning** supera essa limitação ao aprender exclusivamente através da experiência prática, provando-se altamente flexível e eficaz no domínio dinâmico do Pac-Man, desde que respeitados os limites de exploração (ε) e temperança na velocidade de atualização (α).