

MAC0425/7739 - Inteligência Artificial 2026

Lista 2 (Preparação para P2)

Questão 1:** Dê as definições formais dos seguintes modelos de planejamento probabilístico:

- a. MDP de horizonte finito
- b. MDP de horizonte infinito e descontado
- c. SSP

Questão 2: Dado um MDP de horizonte infinito e descontado, dê as definições para as seguintes funções utilidade:

- a) função valor de estado ($V(s)$).
- b) função valor de estado e ação ($Q(s,a)$).

Questão 3: Dada uma política π para um MDP de horizonte infinito descontado, qual é a equação que define a avaliação da política π ?


Questão 4: Descreva a Equação de Otimalidade da Bellman para MDPs de horizonte infinito descontado.

Questão 5: Dê as definições para os seguintes tipos de política:

- a) política parcial
- b) política própria
- c) política gulosa
- d) política ótima

Questão 6**:

Considere o MDP ilustrado da figura abaixo.



Considere a função utilidade local como $R(s) - C(s,a)$ (isto é, recompensa menos o custo); sendo que definimos a função custo para os pares estado/ação, isto é $C(s,a)$, como:

- $C(s, \text{wait}) = 0$ para todo estado s ,
- $C(s,a) = 1$ para toda ação “horizontal”,
- $C(s,a) = 100$ para toda ação “vertical”,

e a função recompensa para o estado, sendo $R(s) = 0$ para todo estado s , exceto para os estados s_4 e s_5 que são definidas por:

- $R(s_4) = 100$
- $R(s_5) = -100$

Considere também que é dada a política π especificada conforme a tabela abaixo.

Estado s	Ação $\pi(s)$
s_1	move($r1, l1, l2$)
s_2	move($r1, l2, l3$)
s_3	move($r1, l3, l4$)
s_4	wait
s_5	move($r1, l5, l4$)

Avaliação de política: aproxime a função valor $V^\pi(s)$ computando 3 iterações na tabela abaixo.

Estado s	V^π (1ª interação)	V^π (2ª interação)	V^π (3ª interação)
s1			
s2			
s3			
s4			
s5			

Questão 7**:

Considere um cenário onde um robô vigilante deve permanecer num corredor de um prédio, sem atrapalhar a passagem das pessoas. Uma vez que do lado esquerdo desse corredor existem portas, o robô atrapalha menos quando permanece do lado direito. Além disso, quando o robô se desloca, a posição desejada é alcançada com probabilidade 0.7 (e com probabilidade 0.3, ele continua na mesma posição em que estava). Em cada instante, o robô deve decidir qual a melhor ação: permanecer onde está ou se mover para direita ou esquerda. Este problema pode ser modelado por um MDP $\langle S, A, P, R, C \rangle$ cujo grafo de transição de estados é dado pela Figura 4. As arestas são rotuladas pelas ações *permanecer*, *paraesq* e *paradir*. E suas probabilidades de transição. Ovais são rotulados pelos estados e o valor de recompensa.




Figura 4. Diagrama de transição de estados para o robô vigilante

Notem que existem três possíveis estados no conjunto S:

s1: Loc = esquerda

s2: Loc = meio

s3: Loc = direita

O conjunto de ações $A = \{\textit{permanecer}, \textit{paraesq}, \textit{paradir}\}$ especifica as possíveis ações do robô; P é a função de transição de estados probabilística, dada por:

$$P(s1 | \textit{permanecer}, s1) = 1.0$$

$$P(s1 | \textit{paradir}, s1) = 0.3$$

$$P(s2 | \textit{paradir}, s1) = 0.7$$

$$P(s2 | \textit{paradir}, s2) = 0.3$$

$$P(s3 | \textit{paradir}, s2) = 0.7$$

$$P(s2 | \textit{paraesq}, s2) = 0.3$$

$$P(s1 | \textit{paraesq}, s2) = 0.7$$

$$P(s3 | \textit{permanecer}, s3) = 1$$

$$P(s3 | \textit{paraesq}, s3) = 0.3$$

$$P(s2 | \textit{paraesq}, s3) = 0.7$$

R é a função que associa recompensas a estados (de modo que posições preferidas sejam melhor recompensadas):

$$R(s1) = 1.0$$

$$R(s2) = 0.0$$

$$R(s3) = 4.0$$

e, finalmente, C é a função custo das ações do robô (de modo que ações preferidas tenham custo menor):

$$C(\textit{permanecer}) = 0$$

$$C(\textit{paraesq}) = 1$$

$$C(\textit{paradir}) = 1$$

Considere a política inicial:

Estado	Ação
s1	<i>permanecer</i>
s2	<i>paradir</i>
s3	<i>permanecer</i>

Sabendo que neste MDP queremos maximizar o valor esperado acumulado descontado de R-C, calcule (manualmente) a política ótima estacionária, com $\gamma = 0.9$, usando o algoritmo de iteração de política especificado a seguir. Note que o algoritmo usa a ideia mas simples de resolução de sistema de equações lineares (Aula 17, slide 58).

Iteração-de-Política (S,A,P,R,C, γ)

```

 $\pi \leftarrow \emptyset$ 
select any  $\pi' \neq \emptyset$ . (política inicial dada)
while  $\pi' \neq \pi$ 
     $\pi \leftarrow \pi'$ 
    for each  $s \in S$ ,
         $E_{\pi}(s) \leftarrow$  solução do sistema de equações
        
$$E_{\pi}(s) = R(s) - C(a) + \gamma \sum_{s' \in S} P(s'|s, \pi(s)) E_{\pi}(s')$$

        for each  $s \in S$ ,
            if  $\exists a \in A \mid E_{\pi}(s) < R(s) - C(a) + \gamma \sum_{s' \in S} P(s'|s, \pi(s)) E_{\pi}(s')$ 
            then  $\pi'(s) \leftarrow a$ 
            else  $\pi'(s) \leftarrow \pi(s)$ 
        endwhile
    return ( $\pi$ )
end

```

Questão 8: Explique a diferença entre os algoritmos Iteração de Valor (IV), Iteração de Política (IP) e *Real Time Dynamic Programming* (RTDP)

Questão 9: Dê uma definição (informal) de Aprendizado por Reforço.

Questão 10:** Explique a diferença entre os seguintes conceitos de Aprendizado por Reforço (AR):

- a. Predição Vs Controle
- b. *Model-Based Vs Model-Free*
- c. Aprendizado por Reforço *on-policy Vs off-policy*

Questão 11:** Considere o cálculo da *média incremental* ((Slides 34-36 da Aula 19), também chamada de média móvel.

- a. Demonstre passo a passo a fórmula da *média incremental* μ_k para uma sequência de x_j valores.
- b. Mostre (explique) como a média incremental é aplicada no método de predição de Monte Carlo para RL. Neste caso, o que seria μ_k ? E o que seria x_j ?
- c. *Mostre (explique) como a média incremental é aplicada no método de predição TD(0). Neste caso, o que seria μ_k ? E o que seria x_j ?*
- d. Explique porque podemos dizer que "**na média incremental corrigimos a média na direção do erro**".

Questão 12. Em um ambiente que pode ser representado por um MDP, dada uma política π para esse ambiente, podemos estimar a função valor da política, $V^\pi(s)$, através de interações com o ambiente, mesmo quando desconhecemos o MDP. Complete as frases:

- e. _____ são métodos que **estimam a função valor** $V^\pi(s)$ amostrando episódios completos de interações com o ambiente.
- b. _____ são métodos que **estimam a função valor** $V^\pi(s)$ amostrando 1 passo a frente de interação com o ambiente e em seguida usam uma estimativa do restante do episódio.
- c. A atualização de $V^\pi(s)$ **usando o método de Monte-Carlo** para predição é dada por:

- d. A atualização de $V^\pi(s)$ **usando o método de TD(0)** para predição é dada por:

Questão 13. Considerando a atualização da função valor usando os métodos MC e TD, explique brevemente os seguintes conceitos:

- f. “*model-free RL*”
- c. “*total (episode) return*”
- d. “*TD target*”
- e. “*TD error*”
- f. “*bootstrapping*”

(Planejamento Automatizado)

Questão 14:

(Ex 10.3 AIMA - modificado) O problema do macaco e das bananas é enfrentado por um macaco em um laboratório com algumas bananas penduradas no teto, fora de seu alcance. Há uma caixa disponível que permitirá ao macaco alcançar as bananas se ele subir nela. Inicialmente, o macaco está na localização A, as bananas em B e a caixa em C. O macaco e a caixa têm a altura *Baixa*, mas, se subir na caixa, o macaco terá a altura *Alta*, a mesma altura das bananas. As ações disponíveis para o macaco incluem *Ir* de um lugar para outro, *Empurrar* um objeto de um lugar para outro, *Subir* em um objeto ou *Descer* de um objeto, e ainda *Pegar* ou *Soltar* um objeto. O resultado de *Agarrar* é que o macaco segura o objeto, se o macaco e o objeto estiverem no mesmo lugar e na mesma altura.

- a. Escreva a descrição do estado inicial.
- b. Escreva os seis operadores de ação.

Questão 15**:

Digamos que você queira desenvolver um sistema de planejamento para um robô **Limpador de Cozinhas**.

Parte a. Escreva o conjunto de operadores STRIPS necessários para resolver esse problema considerando as seguintes propriedades do domínio:

- i. limpar o fogão ou a geladeira deixarão o chão sujo;
- ii. o fogão deve ser limpo antes de fechar a tampa do fogão;
- iii. limpar a geladeira gera lixo e suja a mesa da cozinha;
- iv. limpar a mesa ou o chão suja a pia.


Sua resposta deve usar somente os seguintes predicados ou proposições: limpo(x) (sendo que $\neg$ limpo(x) denota que x está sujo), lixeira-cheia, fogão-fechado e fogão-aberto. Além disso, você deve usar os símbolos constantes: Fogão, Chão, Geladeira, Mesa e Pia. Lembre que os operadores STRIPS podem conter literais positivos e negativos, porém todas as pré-condições devem ser positivas.

Parte b. Escreva uma descrição do estado inicial de uma cozinha em que estão sujos: o fogão, a geladeira, a mesa e o chão. A pia está limpa e a lixeira está vazia.

Parte c. Escreva uma descrição do estado meta em que tudo está limpo, o fogão está fechado, não importando se a lixeira está cheia ou vazia.

Parte d. Qual seria um plano solução para esse problema? Use sua intuição.

Questão 16: Considere o exemplo do livro AIMA, ilustrado pela figura a seguir:



Parte 1. Faça uma descrição dos operadores:

LeftSock (que significa colocar a meia no pé esquerdo)

LeftShoe (que significa colocar o sapato no pé esquerdo)


RightSock (que significa colocar a meia no pé direito)

RightShoe (que significa colocar o sapato no pé direito)

Parte 2. Mostre passo a passo a construção do plano acima utilizando o algoritmo POP.

Questão 15**:

Considere o problema de planejamento com 2 ações, A1 e A2. A ação A1 não tem precondições, mas tem efeitos $\{p, \neg q\}$. A ação A2 tem a precondição q e efeito r . O estado inicial é $\{q\}$. A meta é $\{p, r\}$. O grafo de planejamento expandido (gerado pelo algoritmo GRAPHPLAN) até o nível 1, sem marcações de mutexes, é dado a seguir.



PARTE 1: Marque os mutexes no grafo de planejamento.

PARTE 2: Estenda o grafo até o segundo nível (níveis ação-2 e estado-2) e complete a marcação dos demais mutexes.

PARTE 3: Mostre um plano válido (subgrafo) que corresponda a uma solução.

Questão 16:

(Ex. 10.9 AIMA) Construa os níveis 0, 1 e 2 do grafo de planejamento para o problema da Figura 10.1.

```

Init(At(C1, SFO) ∧ At(C2, JFK) ∧ At(P1, SFO) ∧ At(P2, JFK)
    ∧ Cargo(C1) ∧ Cargo(C2) ∧ Plane(P1) ∧ Plane(P2)
    ∧ Airport(JFK) ∧ Airport(SFO))
Goal(At(C1, JFK) ∧ At(C2, SFO))
Action(Load(c, p, a),
    PRECOND: At(c, a) ∧ At(p, a) ∧ Cargo(c) ∧ Plane(p) ∧ Airport(a)
    EFFECT: ¬ At(c, a) ∧ In(c, p))
Action(Unload(c, p, a),
    PRECOND: In(c, p) ∧ At(p, a) ∧ Cargo(c) ∧ Plane(p) ∧ Airport(a)
    EFFECT: At(c, a) ∧ ¬ In(c, p))
Action(Fly(p, from, to),
    PRECOND: At(p, from) ∧ Plane(p) ∧ Airport(from) ∧ Airport(to)
    EFFECT: ¬ At(p, from) ∧ At(p, to))

```

Figure 10.1 A PDDL description of an air cargo transportation planning problem.

Questão 17:

(Ex. 10.7 AIMA - modificado) A Figura 10.4 mostra um problema de mundo de blocos conhecido como anomalia de Sussman. O problema foi considerado anômalo porque os planejadores sem intercalações do início da década de 1970 não conseguiram resolvê-lo. Escreva uma definição do problema e resolva-o, manualmente com o **Graphplan**. Um planejador sem intercalações é um planejador que, ao receber dois sub objetivos G1 e G2, produz um plano para o G1 concatenado com um plano para G2 ou vice-versa. Explique por que um planejador sem intercalações não consegue resolver esse problema




Figure 10.4 Diagram of the blocks-world problem in Figure 10.3.

Questão 18**:

Parte A. Explique a ideia geral de extração automática de heurísticas de planejamento que fazem a relaxação dos efeitos negativos (Algoritmo de Bellman–Ford, Aula 16, slides 16 e 22).

Parte B. Explique as suposições feitas no cálculo das heurísticas $h_{add}(s)$ e $h_{max}(s)$ usando o algoritmo.